

PROYECTO DE MACHINE LEARNING · CLASIFICACIÓN MULTICLASE

Proyecto ML: Autenticación Vinos

Verificación de cultivar a partir de análisis químico de laboratorio

Ares Cancio Vázquez

github.com/arescanciov/ML_autenticacion_vinos

El problema de negocio

Una cooperativa vinícola recibe partidas de uva/mosto de tres cultivares distintos de la misma región. En puntos críticos del proceso —mezcla de lotes, control de calidad, sospecha de etiquetado incorrecto— es necesario verificar objetivamente a qué cultivar pertenece una muestra, sin depender solo de la declaración del proveedor ni de la cata manual.



Por qué importa

Un lote mal etiquetado que avanza sin detectarse afecta a la trazabilidad, la calidad final y la confianza del cliente en la denominación de origen.

¿Qué decisión mejora con el modelo?

El equipo de control de calidad verifica en segundos el cultivar declarado de una partida, usando análisis de laboratorio que ya se hacen de forma rutinaria — sin coste adicional de muestreo.

Plan de acción

Si el modelo predice un cultivar distinto al declarado, con alta confianza, la partida se marca para revisión manual antes de continuar el proceso. Si coincide, sigue el flujo estándar.


Planteamiento técnico

Tipo de problema	Clasificación multiclase supervisada — 3 cultivos
Variable target	cultivar_0 / cultivar_1 / cultivar_2
Métrica principal	F1-macro (mismo peso para cada cultivar)
Métricas complementarias	Accuracy · Recall-macro · ROC-AUC (One-vs-Rest)
División de datos	80% train / 20% test, estratificada
Validación	Cross-validation estratificada, 5 folds

Se prioriza F1-macro frente a Accuracy porque ningún cultivar pesa más que otro en el negocio: el coste de confundir cualquier par de cultivos es similar.

El dataset: Wine Data Set

178 registros con 13 variables químicas numéricas procedentes de un análisis de laboratorio estándar (alcohol, ácido málico, magnesio, fenoles, flavonoides, intensidad de color, tono, prolina, etc.), correspondientes a vinos de tres cultivares cultivados en la misma región.



Balance de clases en train (33% / 40% / 27%)

178

muestras totales

13

variables químicas

3


cultivares

0

missings / duplicados

Dataset público, ampliamente validado en la literatura de clasificación multiclase.

Las variables más discriminantes





Ranking por dos métodos

ANOVA F-test (relaciones lineales entre medias) e Información Mutua (también relaciones no lineales) coinciden en señalar las mismas variables como más discriminantes:

- **flavanoids**
- **proline**
- **color_intensity**
- **od280/od315_of_diluted_wines**

En estas variables, las cajas de los 3 cultivares apenas se solapan.

Separabilidad de clases: PCA vs. LDA



PCA (no supervisado)

Busca la mayor varianza en los datos, sin usar el target. Las clases ya se distinguen razonablemente.

LDA (supervisado)

Maximiza explícitamente la separación entre clases. Los tres cultivares quedan casi perfectamente separados.

Conclusión: el problema es altamente "aprendible" — un modelo simple ya debería rendir muy bien.

Preprocesado y Feature Engineering

Escalado

StandardScaler

Necesario para modelos lineales, SVM y KNN

Feature engineering

Ratios + interacción química

Señal relativa entre compuestos del vino

Selección de features


RFE — 10 variables

Reduce redundancia y mejora interpretabilidad

Variables derivadas creadas

+	phenols_flavanoid_ratio	Proporción de fenoles totales que no son flavonoides
+	alcohol_color_interaction	Interacción entre grado alcohólico e intensidad de color
+	flavanoid_hue_ratio	Ratio flavonoides / tono, discriminante en la literatura

Comparativa de algoritmos



Ganadores

LogisticRegression y SVM obtienen el mejor F1-macro y ROC-AUC en validación cruzada — coherente con la fuerte separabilidad casi lineal observada en LDA.

Optimización (GridSearchCV)

F1-macro CV: 0.9927

Modelo final: Logistic Regression (C=0.1)

Evaluación final sobre test

100%

Accuracy

100%


Precision (macro)

100%

Recall (macro)

100%

F1 (macro)



El modelo clasifica correctamente las 36 muestras del conjunto de test, sin ningún error entre cultivos.

Resultado coherente con la altísima separabilidad observada en el EDA (LDA, ranking ANOVA/MI). Es un resultado esperable en este dataset de referencia, de tamaño reducido y ampliamente validado en la literatura — a interpretar con la cautela propia de un test de solo 36 muestras.

CONCLUSIONES

De la exploración al despliegue

1

Pipeline de ML completo y reproducible que cumple el objetivo de negocio: verificar el cultivar declarado a partir de análisis químico rutinario.

2

El EDA ampliado (ranking ANOVA/MI, outliers multivariantes, PCA vs. LDA) anticipó la altísima separabilidad, confirmada en los resultados.

3

El modelo final ofrece un F1-macro del 100% en test, sin errores de clasificación entre cultivares.

LIMITACIONES Y PRÓXIMOS PASOS

Validar con muestras de otras campañas y regiones · Estudiar el coste real de cada tipo de confusión entre cultivares · Desplegar como servicio de apoyo al laboratorio de control de calidad.